phred_score.py 사용 설명서

1. 개요

doc/phred_score.py 는 FASTQ 의 **품질 문자열(4번째 줄) 하나**를 받아서

- 각 위치의 **품질 점수(Phred score, Q)** 와 **오류 확률**을 표로 출력하고,
- 전체 위치의 **점수 합계와 평균 품질 점수**를 계산하는 스크립트이다.

표준 라이브러리(sys)만 사용하므로 별도 설치 없이 실행된다.

2. 품질 점수 계산 원리 (Phred+33)

FASTQ 의 품질 문자열은 각 염기의 품질 점수를 문자 하나로 바꿔 적은 것이다. 현재 대부분의 FASTQ(Illumina 1.8 이상)는 **Phred+33** 인코딩을 쓴다.

```
Q = (문자의 ASCII 코드) - 33
오류 확률 P = 10^(-Q/10)
```

문자	ASCII	Q	오류 확률	의미
#	35	2	0.6310	거의 믿을 수 없음
+	43	10	0.1	10번에 1번 틀림
5	53	20	0.01	100번에 1번 틀림
?	63	30	0.001	1000번에 1번 틀림
I	73	40	0.0001	10000번에 1번 틀림

3. 사용법

lab11 폴더 안에서 실행한다.

```
cd lab11
python3 doc/phred_score.py [품질 문자열]
```

- 품질 문자열을 **생략하면** 예제 문자열 IIIIIIII#####IIIIIIIII 을 사용한다.
- 품질 문자열을 **직접 줄 때는 작은따옴표 ' ' 로 감싼다.** # 은 셸에서 주석 기호이고, ! ·*·& 등도 셸이 다르게 해석하기 때문이다.

3-1. 예제 문자열로 실행

```
python3 doc/phred_score.py
```

출력 결과:

```
품질 문자열: IIIIIIII#####IIIIIIIII
길이: 23

위치          문자          ASCII         Q             오류확률
1             I             73            40            0.0001
2             I             73            40            0.0001
...
8             I             73            40            0.0001
9             #             35            2             0.6310
10            #             35            2             0.6310
11            #             35            2             0.6310
12            #             35            2             0.6310
13            #             35            2             0.6310
14            I             73            40            0.0001
...
23            I             73            40            0.0001

점수 합계: 730
평균 품질 점수: 31.74
```

3-2. 다른 품질 문자열로 실행

```
python3 doc/phred_score.py 'FFFF:::,,#'
```

4. 출력 항목 설명

항목	설명
위치	서열에서 몇 번째 염기인지 (1부터 셈)
문자	품질 문자열의 해당 문자
ASCII	그 문자의 ASCII 코드 (ord() 결과)
Q	Phred 품질 점수 = ASCII − 33
오류확률	그 염기를 잘못 읽었을 확률 = 10^(−Q/10)
점수 합계	모든 위치의 Q 를 더한 값
평균 품질 점수	점수 합계 ÷ 길이 (소수점 둘째 자리까지)

5. 예제 결과 해석

- I 18개 × 40점 + # 5개 × 2점 = **730점**, 730 ÷ 23 = **평균 31.74**
- 평균만 보면 Q30 이상이라 괜찮아 보이지만, **9~13번째 염기 5개는 Q=2(오류 확률 약 63%)** 로 사실상 믿을 수 없다.
- 그래서 품질은 **평균 하나만 보지 말고 위치별 점수를 함께 확인해야 한다.** (FastQC 의 "Per base sequence quality" 그래프를 보는 것과 같은 이유이다.)

6. 코드 구조

함수	하는 일
phred_scores(quality)	품질 문자열을 받아 각 위치의 Q 점수 리스트를 돌려준다
main()	명령줄 인자를 읽고, 위치별 표와 합계·평균을 출력한다

다른 스크립트에서 함수만 가져다 쓸 수도 있다.

```
from phred_score import phred_scores

scores = phred_scores("IIII####")
print(scores)                    # [40, 40, 40, 40, 2, 2, 2, 2]
print(sum(scores) / len(scores))  # 21.0
```

7. 주의할 점

- **Phred+33 전용**이다. 아주 오래된 Illumina(1.3~1.7) 데이터의 Phred+64 형식에서는 점수가 31만큼 크게 나온다.
- **품질 문자열 한 줄만** 처리한다. FASTQ 파일 전체를 처리하려면 src/qual_summary.py 를 사용한다.
- 빈 문자열 '' 을 주면 길이가 0이라 평균을 낼 때 ZeroDivisionError 가 난다.