qual_by_position.py 사용 설명서

1. 개요

src/qual_by_position.py 는 FASTQ 파일의 **모든 read 에서 같은 위치(1번째 염기, 2번째 염기, ...)의 품질 점수를 모아 위치별 평균 품질**을 계산하는 스크립트이다.

- 결과는 위치<TAB>평균품질 형식으로 한 줄에 한 위치씩 출력한다.
- FastQC 의 "Per base sequence quality" 그래프에 들어가는 값(위치별 평균)을 직접 계산해 보는 것과 같다.
- 표준 라이브러리(sys)만 사용하므로 별도 설치 없이 실행된다.

2. 사용법

lab11 폴더 안에서 실행한다.

```
cd lab11
python3 src/qual_by_position.py <FASTQ 파일 경로>
```

FASTQ 파일을 주지 않으면 사용법을 안내하고 종료한다.

2-1. 실행 예시

```
python3 src/qual_by_position.py data/SRR1553607_1.fastq
```

출력 결과 (중간 생략):

```
위치            평균품질
1               32.04
2               32.17
3               32.28
4               35.85
5               35.65
...
50              33.44
...
99              29.03
100             28.93
101             28.25
```

2-2. 결과를 파일로 저장하기

출력이 위치 개수만큼 길기 때문에 파일로 저장해 두면 편하다.

```
python3 src/qual_by_position.py data/SRR1553607_1.fastq > doc/qual_by_position_raw.tsv
python3 src/qual_by_position.py data/trimmed.fastq      > doc/qual_by_position_trimmed.tsv
```

탭으로 구분된 파일(.tsv)이므로 엑셀·구글 시트에서 열어 그래프를 그릴 수 있다.

3. 출력 형식

열	설명
위치	read 안에서 몇 번째 염기인지 (1부터 셈)
평균품질	그 위치를 가진 모든 read 의 Phred 품질 점수 평균 (소수점 둘째 자리까지)

품질 점수는 **Phred+33** 인코딩으로 계산한다.

```
Q = (품질 문자의 ASCII 코드) - 33      예) 'I' -> 40, '#' -> 2
```

4. 계산 방법: 길이가 다른 read 처리

트리밍한 파일처럼 read 마다 길이가 다를 수 있다. 이 스크립트는 **위치마다 두 가지 값을 따로 센다.**

- sums[i] : i 번째 위치의 품질 점수 합계
- counts[i] : i 번째 위치를 **가진** read 의 수

```
위치별 평균 = sums[i] / counts[i]
```

예를 들어 다음 두 read 가 있다면

```
read1 품질: II##   (길이 4, 점수 40 40 2 2)
read2 품질: 55     (길이 2, 점수 20 20)
```

위치	점수들	read 수	평균
1	40, 20	2	30.00
2	40, 20	2	30.00
3	2	1	2.00
4	2	1	2.00

3·4번째 위치는 read2 에 없으므로 read1 의 값만으로 평균을 낸다. "가장 짧은 read 길이까지만 계산" 하는 방법과 달리, 긴 read 의 뒷부분 정보도 버리지 않는다.

5. 결과 해석 예시

트리밍 전(SRR1553607_1.fastq, 모든 read 101 bp)과 후(trimmed.fastq, read 길이 50~101 bp)를 비교하면:

위치	트리밍 전	트리밍 후
1	32.04	32.25
3	32.28	32.49
101	28.25	29.97

- 두 파일 모두 **3′ 끝(뒤쪽 위치)으로 갈수록 품질이 떨어지는** 전형적인 Illumina 패턴을 보인다.
- 트리밍 후에는 같은 위치의 평균이 더 높다. 품질이 낮은 부분과 read 가 제거되었기 때문이다.

6. 코드 구조

함수	하는 일
qual_by_position(filename)	FASTQ 를 한 줄씩 읽어 4번째 줄(품질 문자열)마다 위치별 합계·개수를 더하고 (sums, counts) 를 돌려준다
main()	명령줄 인자를 확인하고, 위치별 평균을 탭으로 구분해 출력한다

파일 전체를 한꺼번에 메모리에 올리지 않고 **한 줄씩** 읽기 때문에 큰 FASTQ 파일도 처리할 수 있다.

7. 주의할 점

- **Phred+33 전용**이다. 아주 오래된 Illumina(1.3~1.7) 의 Phred+64 데이터에서는 점수가 31만큼 크게 나온다.
- FASTQ 가 **정확히 4줄에 read 하나**인 형식이라고 가정한다. 서열이 여러 줄로 나뉜 FASTQ 나 빈 줄이 섞인 파일에서는 엉뚱한 줄을 품질로 읽는다.
- 압축 파일(.fastq.gz)은 바로 읽지 못한다. 먼저 gunzip 으로 풀거나 zcat 으로 풀어 저장한 뒤 사용한다.

- 뒤쪽 위치일수록 그 위치를 가진 read 수가 적을 수 있다. read 수가 아주 적은 위치의 평균은 몇 개 read 에 크게 좌우되므로 해석에 주의한다.